

Молекулярная биология

1 подгруппа

Заметим, что если мы начинаем набирать слово с позиции s , то не существует двух различных слов из словаря $\overline{a_s a_{s+1} \dots a_{s+i}}$ и $\overline{a_s a_{s+1} \dots a_{s+j}}$, так как одно из них было бы префиксом другого, что запрещено по условию.

Следовательно, из каждой позиции строки однозначно определяется слово словаря, которое может начинаться в этой позиции (если оно вообще существует).

Предподсчитаем для каждой позиции i :

- существует ли слово словаря, начинающееся в i ,
- если существует — позицию его конца.

Это можно сделать прямой проверкой за $O(SL)$, где S — суммарная длина слов словаря, L — длина белка.

Теперь обработка одного запроса $[l, r]$ происходит так:

- начинаем с позиции l ,
- переходим к концу найденного слова,
- продолжаем, пока текущая позиция не станет равной $r + 1$.

Если мы перепрыгнули за $r + 1$, разбиение невозможно.

Таким образом, сложность: $O(SL + LM)$

2 подгруппа

Предподсчёт из предыдущего решения слишком дорогой.

Построим бор по всем словам словаря. Тогда мы можем проходить по белку посимвольно.

Алгоритм:

- идём по буквам строки,
- двигаемся по бору,
- если пришли в терминальную вершину, значит найдено слово,
- переносим указатель в корень бора и увеличиваем ответ.

Так как ни одно слово не является префиксом другого, терминальность однозначно определяет завершение слова.

Предобработка занимает $O(S)$, а каждый проход по фрагменту — $O(L)$.

Итоговая сложность: $O(S + LM)$.

3 подгруппа

Используем хеширование.

Сохраним в `set` или `unordered_set` хеши всех префиксов слов словаря. Также посчитаем префиксные хеши строки белка.

Для позиции s можно бинарным поиском найти длину слова, начинающегося в s , сравнивая хеши за $O(\log S)$ и проверять, есть ли он в `set`.

Заметим, что из каждой позиции может начинаться не более одного слова.

Построим ориентированное ребро $i \rightarrow j+1$, если из позиции i начинается слово, заканчивающееся в позиции j .

Так как из каждой вершины выходит не более одного ребра, получаем лес.

Тогда:

- разбиение существует тогда и только тогда, когда вершина l лежит в поддереве вершины $r + 1$,
- это можно проверить через времена входа и выхода (tin , $tout$),
- ответ равен разности глубин.

Сложность:

$$O(S \log S + L \log^2 S + Q)$$

или

$$O(S + L \log S + Q),$$

в зависимости от структуры хранения хешей.

Полное решение

Заметим, что структура переходов полностью совпадает с автоматом Ахо–Корасик.

Построим автомат по словарю за

$$O(SA),$$

где A — размер алфавита.

Суперсуффиксные ссылки (output links) соответствуют тем самым переходам из решения 3 подгруппы. После каждого перехода по суперсуффиксной ссылке мы добавляем одно ребро в лес.

Тогда:

- при проходе по белку мы получаем все окончания слов,
- строим граф переходов,
- далее отвечаем на запросы так же, как в 3 подгруппе.

Тогда суперсуффиксных переходов $O(L)$, так как из каждого индекса i выходит не более одного ребра.

Итоговая сложность:

$$O(SA + (L + S) + Q).$$